

# Tarea 5. Optimización

Oscar Esaú Peralta Rosales  
Maestría en Computación  
Centro de Investigación en Matemáticas

**Resumen**—A continuación se presentan la implementación y resultados de dos algoritmos de región de confianza, el primero el Algoritmo de *Dogleg* y el segundo una modificación al algoritmo de obtención del paso y dirección de descenso a través de usar descenso de gradiente sobre el modelo  $m_k$  a optimizar. Por último se presenta la solución a un problema de segmentación a través del histograma generado por los colores de una imagen y se compara contra una aproximación a dicho histograma usando funciones de base radial (en este caso la gaussiana) a través de la optimización de las medias y los coeficientes de ponderación de cada función base radial.

**Index Terms**—Región de Confianza, Dogleg, Funciones de Base Radial

## I. INTRODUCTION

Al igual que los métodos de búsqueda en línea los métodos basados en región de confianza generan cada paso a través de un modelo cuadrático de la función objetivo, en donde se define un región alrededor del valor de la iteración actual y se elige un paso (junto con su tamaño) que minimice el modelo en la en dicha región bajo la premisa de que el modelo es una buena representación de la función objetivo en la región. El tamaño de la región se actualiza de acuerdo a el rendimiento de la iteración anterior, si el modelo es bastante confiable y produce pasos consistentes en el la región puede ser incrementada de tamaño. Si no se encuentra un paso válida entonces el tamaño de la región se decremente hasta encontrar alguno [1].

El modelo está dado por:

$$m_k(p) = f_k + g_k^T p + \frac{1}{2} p^T B_k p \quad (1)$$

Dónde  $B_k$  es el Hessiano de  $f$ . Para obtener cada paso entonces se busca minimizar el problema

$$\min_{p \in \mathcal{R}^n} m_k(p) = f_k + g_k^T p + \frac{1}{2} p^T B_k p, \quad \|p\| \leq \Delta_k \quad (2)$$

Donde  $\Delta_k$  es el radio de la región de confianza. Este radio es incrementado y reducido dependiendo del cociente

$$\rho_k = \frac{f(x_k) - f(x_k + p_k)}{m_k(0) - m_k(p_k)} \quad (3)$$

Si  $\rho_k < \frac{1}{4}$  decrementamos el radio a un cuarto de su valor, si  $\rho_k > \frac{3}{4}$  elegimos  $\Delta_{k+1} = \min(2\Delta_k, \hat{\Delta})$ , con  $\hat{\Delta}$  como el radio máximo.

Uno de los métodos para la obtención del tamaño de paso y la dirección de descenso  $p_k$  es a través del método de *Dogleg*. Se elige remplazar la curva de trayectoria óptima de la solución que minimiza a  $m_k$ , por dos segmentos desde el origen del minimizador a el punto  $p_k^u$  y del punto  $p_k^u = -\frac{g_k^T g_k}{g_k^T B_k g_k}$  al punto  $p_k^B$ , donde  $p_k^B = -B_k^{-1} g_k$  es la solución óptima al problema sin restricciones (2).

Si  $\Delta_k > \|p_k^B\|$  la solución es precisamente  $p_k = p_k^B$ , si  $\Delta_k > \|p_k^u\|$  la solución es  $p_k = p_k^u \frac{\Delta_k}{\|p_k^u\|}$ , de lo contrario la solución es la proporción  $\tau$  de  $p_k^B$  de la intersección de la región de confianza con el segmento  $p_k^u$  a  $p_k^B$ .

La segunda forma de obtención del paso y dirección de descenso  $p_k$  se describe el algoritmo 1 del Apéndice. La idea central es aplicar descenso de gradiente sobre  $m_k$  para obtener un nuevo punto  $z_j$  que minimize  $m_k$  a través de la dirección  $d_j$ , en el momento que  $\|z_j\| \geq \Delta_k$  o  $d_j^T B_k d_j \leq 0$  buscamos la intersección de la región de confianza con el segmento  $z_j$  a  $d_j$  tal que  $\|z_j + \tau d_j\| = \Delta_k$  con  $p_k = z_j + \tau d_j$ .

La función a optimizar para aproximar un histograma en 3D a través de funciones base con kernel gaussiano está dada por minimizar siguiente error:

$$\min_{\alpha^j, \mu^j} g(\alpha^j, \mu^j)$$

$$g(\alpha^j, \mu^j) = \sum_{c \in \Omega} \left[ h^j(c) - \sum_i^n \alpha_i^j \exp\left(\frac{-\|c - \mu_i^j\|_2^2}{2\sigma^2}\right) \right]^2 \quad (4)$$

Donde:

- $j \in \{1, 2\}$  corresponden al fondo y al objeto.
- $c = [r, g, b]^T$ , con  $r \in B_1 = \{1, \dots, b_1\}$ ,  $g \in B_2 = \{1, \dots, b_2\}$  y  $b \in B_3 = \{1, \dots, b_3\}$  son el número de bins en cada cana RGB.
- $\Omega = B_1 B_2 B_3$ , donde  $X \times Y := \{(x, y) : x \in X, y \in Y\}$  representa el producto cartesiano.
- $h^j(r, g, b)$  es el histograma en 3D de la clase  $j$ .
- $n$  es el número de elementos de la base radial.
- $\alpha^j = [\alpha_1^j, \dots, \alpha_n^j]$  son los pesos de la combinación lineal de la base radial
- $\mu^j = [\mu_1^j, \dots, \mu_n^j]$  son las medias de cada función base.
- $\sigma$  es un parámetro ajustable.

Así, buscamos optimizar los valores de  $\alpha^j$  y  $\mu^j$  tal que el error sea mínimo.

## II. MÉTODOLÓGÍA

### II-A. Algoritmo de Región de Confianza: Dogleg

Como se mencionó anteriormente los algoritmos de región de confianza se pueden dividir generalmente en dos pasos, el primero es buscar una dirección y tamaño de paso  $p_k$  que minimize el modelo  $m_k(p_k)$  y luego encontrado  $p_k$  necesitamos decidir si podemos aumentar o disminuir la región de confianza dado el coeficiente  $\rho_k$  (Apéndice V–A–Algoritmo 1).

El algoritmo de Dogleg se describe en el Apéndice V–A–Algoritmo 2. Se probó usando la función de Rosembrock con  $n = 100$  y la función de Wood.

### II-B. Algoritmo de Región de Confianza: Descenso de gradiente sobre el modelo

Para realizar la implementación de este variante se procedió primero a realizar el calculo del valor de  $\tau$  tal que  $\|z_j + \tau d_j\| = \Delta_k$ , expandiendo el tenemos que  $d_j^T d_j \tau^2 + 2z_j^T d_j \tau + z_j^T z_j - \Delta_k^2 = 0$ , hacemos  $a = d_j^T d_j$ ,  $b = 2z_j^T d_j$  y  $c = z_j^T z_j - \Delta_k^2$ , así podemos obtenemos lo coeficientes de una ecuación cuadrática y resolver para  $\tau$  usando la fórmula general.

$\alpha_j = \arg \min_{\alpha > 0} m_k(z_j + \alpha d_j)$ , derivando e igualando a cero tenemos que  $\alpha_j = -\frac{g_k^T d_j + z_j^T B_k d_j}{d_j^T B_k d_j}$ . El algoritmo completo implementado se encuentra en el Apéndice V–A.

### II-C. Aproximación de histograma en 3D a través de funciones base radial con kernel gaussiano

Los parámetros  $\alpha^j$  y  $\mu^j$  a optimizar de la función (4) son obtenidos optimizando por separado fijando  $\alpha^j$  y luego  $\mu^j$  hasta convergencia:

$$\alpha_{k+1}^j = \arg \min_{\alpha^j \in (R)^n} g(\alpha^j, \mu_k^j)$$

$$\mu_{k+1}^j = \arg \min_{\mu^j \in (R)^n} g(\alpha_k^j, \mu^j)$$

Notemos que para realizar la optimización necesitamos calcular dos gradientes un con respecto a  $\alpha^j$  y otro con respecto a  $\mu^j$  donde cada entrada del gradiente está dadas por:

$$\frac{\partial}{\partial \alpha_k^j} - 2 \sum_{c \in \Omega} \left[ h^j(c) - \sum_i \alpha_i^j \exp^{-w_i} \right] \exp^{w_k}$$

y

$$\frac{\partial}{\partial \mu_k^j} - \frac{2}{\sigma^2} \sum_{c \in \Omega} \left[ h^j(c) - \sum_i \alpha_i^j \exp^{-w_i} \right] \alpha_k \exp^{-w_k} (c - \mu_k^j)$$

$$\text{donde } w_i = \frac{\|c - \mu_i^j\|_2^2}{2\sigma^2}$$

Durante la implementación se utilizó el algoritmo de optimización de Barzilai-Borwein, nótese que para otros algoritmos es necesario calcular el Hessiano.

La generación del histograma 3D de una imagen se genera con ayuda de un script en python el cuál nos

permite marcar con dos colores rojo y azul, el objeto y el fondo. Posteriormente para cada pixel de alguna imagen se mapea a su correspondiente valor  $c$  y después de la optimización sobre el fondo y el objeto se elige el color mediante:

$$f(c, \alpha^j, \mu^j) = \sum_i \alpha_i^j \exp\left(\frac{-\|c - \mu_i^j\|_2^2}{2\sigma^2}\right)$$

$$F(c, \alpha^1, \mu^1) = \frac{f(c, \alpha^1, \mu^1) + \epsilon}{f(c, \alpha^1, \mu^1) + f(c, \alpha^2, \mu^2) + 2\epsilon}$$

$$F(c, \alpha^2, \mu^2) = \frac{f(c, \alpha^2, \mu^2) + \epsilon}{f(c, \alpha^1, \mu^1) + f(c, \alpha^2, \mu^2) + 2\epsilon}$$

Con  $\epsilon = 0,01$  y si  $F(c, \alpha^1, \mu^1) < F(c, \alpha^2, \mu^2)$  asignar al pixel el color azul de lo contrario el color rojo.

Realizando lo mismo a través del histograma en 3D tenemos que:

$$H1(c) = \frac{h^1(c) + \epsilon}{h^1(c) + h^2(c) + 2\epsilon}$$

$$H2(c) = \frac{h^2(c) + \epsilon}{h^1(c) + h^2(c) + 2\epsilon}$$

Si  $H1(c) < H2(c)$  asignar al pixel el color azul de lo contrario el color rojo.

## III. RESULTADOS

### III-A. Algoritmo de Región de Confianza: Dogleg

En la tabla I se muestra una comparativa del rendimiento del método con las dos funciones. Nótese que los resultados obtenidos son para el mínimo local ya conocido.

Cuadro I  
TABLA COMPARATIVA DEL MÉTODO DE DOGLE

Función	Iteraciones	$\ g_k\ $	$ f(x_k) - f(x^*) $
Rosembrock	61	9.9986	3.9866
Wood	44	1.9180	7.8769




Figura 1. Decremento de la función objetivo a través de las iteraciones, Rosembrock

### III-B. Algoritmo de Región de Confianza: Descenso de gradiente sobre el modelo

En la tabla II se muestra una comparativa del rendimiento del método con las dos funciones. Nótese que los resultados obtenidos son para el mínimo local ya conocido para el caso de la función de Rosembrock y al óptima para la función de Wood.

Cuadro II  
TABLA COMPARATIVA DEL MÉTODO USANDO DESCENSO DE GRADIENTE SOBRE EL MODELO

<b>Función</b>	<b>Iteraciones</b>	$\ g_k\ $	$ f(x_k) - f(x^*) $
Rosembrock	352	9.9986	3.9866
Wood	250	2.0000	4.2463e-13




Figura 2. Decremento de la función objetivo a través de las iteraciones, Wood

### III-C. Aproximación de histograma en 3D a través de funciones base radial con kernel gaussiano

Se realizaron las pruebas sobre diversos grupos de imágenes, todos los histogramas se obtuvieron a través del script en python brindado. Las siguientes imágenes muestran los mejores resultados obtenidos para las imágenes.

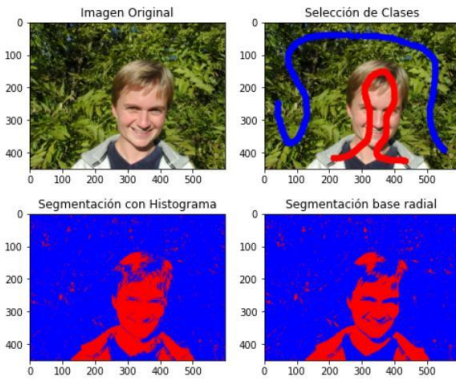


Figura 3. Segmentación a través del histograma y la aproximación a este,  $bins = 3$ , funciones base = 30,  $\sigma = 20$




Figura 4. Segmentación a través del histograma y la aproximación a este,  $bins = 3$ , funciones base = 30,  $\sigma = 0,1$

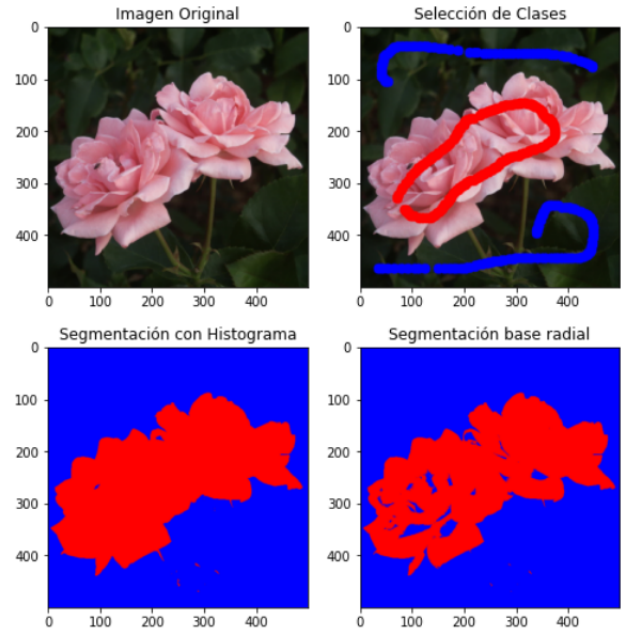


Figura 5. Segmentación a través del histograma y la aproximación a este,  $bins = 3$ , funciones base = 30,  $\sigma = 0,1$

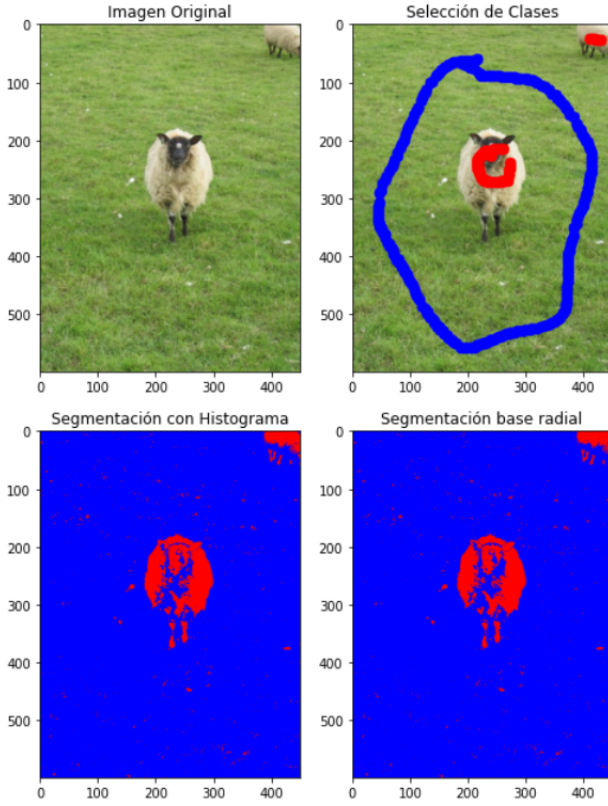


Figura 6. Segmentación a través del histograma y la aproximación a este,  $bins = 3$ , funciones base = 30,  $\sigma = 0,1$

#### IV. CONCLUSIONES

Como se mencionó anteriormente en los métodos de región de confianza el cálculo del tamaño de paso y la dirección de gradiente puede ser en diversas formas. En este caso se implementaron dos formas la primera a través del método de Dogleg, el cual tratar de aproximar la trayectoria de la solución mediante dos segmentos formados por el origen y el punto  $p_k^U$  y de  $p_k^U$  a el punto  $p_k^B$ . La segunda forma fue interar sobre el modelo hasta encontrado un tamaño de paso y dirección valido a través de descenso de gradiente sobre el modelo. Como se observa en los resultados la convergencia del método de Dogleg es mucho más rápida que la segunda aproximación covergiendo al rededor de 60 iteraciones vs 300 iteraciones del método usando descenso. En este caso con ambos métodos no se pudo obtener el mínimo óptimo llegando solo al local para la función de Rosembrock, y llegando al mínimo óptimo para la función de Wood solo en el segundo método de para la obtención de  $p_k$ .

Para varias imágenes, las aproximaciones a los histogramas fueron similares, mostrando imágenes segmentadas con muy pocas diferencias. Sin embargo, para poder alcanzar resultados buenos la clave es encontrar valores de  $\sigma$  que nos permitan aproximarla de la mejor manera.

Por lo regular con alrededor de 60 a 80 funciones base los resultados son bastante buenos. El número de bins usados para la generación de los histogramas es de 3, un número mayor de bins provoca un incremento substancial en el tiempo de ejecución y convergencia (horas).

#### V. APÉNDICE

##### V-A. Algoritmos

---

###### Algorithm 1: Algoritmo de Región de Confianza

---

```

Result:  $x_k$ 
 $x_k \leftarrow$  Inicializar
while  $\|g_k\| > tol$  do
    Calcular  $p_k$  que minimize el modelo  $m_k(p_k)$ 
     $\rho_k = \frac{f(x_k) - f(x_k + p_k)}{m_k(0) - m_k(p_k)}$ 
    if  $\rho < \frac{1}{4}$  then
         $\delta_k = \frac{1}{4} \Delta_k$ 
    end
    else if  $\rho > \frac{3}{4}$  then
         $\delta_k = \min(2\Delta_k, \hat{\Delta})$ 
    end
    if  $\rho \leq \eta$  then
        continue
    end
     $x_k = x_k + p_k$ 
end

```

---



---

###### Algorithm 2: Método de Dogleg, cálculo de $p_k$

---

```

Result:  $p_k$ 
 $g_k \leftarrow$  Ingresar
 $B_k \leftarrow$  Ingresar
 $\Delta_k \leftarrow$  Ingresar
while  $\|g_k\| > tol$  do
     $p_k^U = \frac{g_k^T g_k}{g_k^T B_k g_k}$ 
     $p_k^B = -B_k^{-1} g_k$ 
    if  $\|p_k^B\| \leq \Delta_k$  then
         $p_k = p_k^B$ 
    end
    if  $\|p_k^U\| \geq \Delta_k$  then
         $p_k = p_k^U \frac{\Delta_k}{\|p_k^U\|}$ 
    end
    else
         $a = \|p_k^B - p_k^U\|^2$ 
         $b = 2p_k^B (p_k^B - p_k^U)$ 
         $c = \|p_k^U\|^2 - \Delta_k^2$ 
         $\lambda = \frac{-b + \sqrt{b^2 - 4ac}}{2a} : \lambda \in [0, 1]$ 
         $\tau = \lambda + 1$ 
         $p_k = p_k^U + (\tau - 1, 0) * (p_k^B - p_k^U)$ 
    end
end

```

---

---

**Algorithm 3:** Descenso de gradiente sobre  $m_k(p)$   
para cálculo de  $p_k$

---

**Result:**  $p_k$

$j = 0$

$z_0 = 0$

$d_0 = -\nabla m_k(z_0)$

$g_k \leftarrow$  Ingresar

**while**  $\|d_j\| \neq 0, j < J$  **do**

**if**  $\|d_j^T B_k d_j \leq 0\|$  **then**

$a = d_j^T d_j$

$b = 2z_j^T d_j$

$c = z_j^T z_j - \Delta^2$

$\tau = \frac{-b + \sqrt{b^2 - 4ac}}{2a} : \tau \geq 0$

        return  $p_k = z_j + \tau d_j$

**end**

$\alpha_j = -\frac{g_k^T d_j + z_j^T B_k d_j}{d_j^T B_k d_j}$

$z_{j+1} = z_j + \alpha_j d_j$

**if**  $\|z_{j+1}\| > \Delta_k$  **then**

$a = d_j^T d_j$

$b = 2z_j^T d_j$

$c = z_j^T z_j - \Delta^2$

$\tau = \frac{-b + \sqrt{b^2 - 4ac}}{2a} : \tau \geq 0$

        return  $p_k = z_j + \tau d_j$

**end**

$d_j = -\nabla m_k(z_{j+1})$

$j++$

**end**

$p_k = z_{j+1}$  return  $p_k$

---

## REFERENCIAS

- [1] Jorge Nocedal, Stephen J. Wright, "Numerical Optimization,"  
Second Edition, Springer.